Analyse des structures économiques des pays industrialisés et des pays riches en ressources naturelles à l'aide de modèles CGGM

Toulouse School of Economics

18 décembre 2025

Alexandre Picart – Rémi Lahay – Anas Naji

Plan de la présentation

1. Motivation et données
2. Gaussian Graphical Models
3. Clusterpath Gaussian Graphical Modeling
4. Application du CGGM
5. Conclusion

Motivation

- Intérêt du sujet : comparer les **structures économiques** de différents groupes de pays permet de mieux comprendre **comment les mécanismes macroéconomiques s'organisent** selon le niveau de développement et la dépendance aux ressources naturelles.
- L'analyse d'une variable isolée est insuffisante pour comprendre des **systèmes économiques complexes**.
- Lorsque le nombre de variables augmente et devient trop important par rapport au nombre d'observations, ces analyses deviennent **difficiles à interpréter**.
- Les **Gaussian Graphical Models** permettent d'identifier les dépendances conditionnelles directes, et le **CGGM** améliore leur lisibilité en regroupant les variables aux comportements similaires.

Base de données

- Données issues de la base *World Development Indicators (WDI)* de la **Banque mondiale**.
- Observations **annuelles** au niveau des pays, sur la période **2005–2021**.
- Échantillon final :
  - **19 pays :** France, États-Unis, Royaume-Uni, Japon, Canada, Corée du Sud, Espagne, Italie, Pays-Bas, Suède, Suisse, Allemagne, Chili, Norvège, Algérie, Kazakhstan, Angola, Azerbaijan, Russie
  - **10 variables continues**
  - **391 observations**

Analyse exploratoire

Table: Statistiques descriptives des variables macroéconomiques

Variable	Moyenne	Écart-type
Croissance du PIB (%)	2.65	4.65
PIB par habitant (USD constants 2015)	34 199	22 883
Rentes des ressources naturelles (% du PIB)	10.80	14.00
Formation brute de capital (% du PIB)	25.01	6.61
Valeur ajoutée industrielle (% du PIB)	31.79	13.34
Dépenses nationales brutes (% du PIB)	92.15	11.21
Inflation (prix à la consommation, %)	3.84	4.86
Commerce de marchandises (% du PIB)	60.65	29.67
Efficacité du gouvernement (indice)	0.80	0.99
IDE nets sortants (% du PIB)	4.27	8.76

Prétraitement des données : Modèle HAR

- Les séries macroéconomiques annuelles présentent une forte **dépendance temporelle intra-pays**.
- Objectif : analyser les relations structurelles entre variables **indépendamment des dynamiques temporelles**.
- Solution : le **modèle hétérogène autorégressif (HAR)**

$$y_{i,t} = \alpha_i + \beta_1 y_{i,t-1} + \beta_5 y_{i,t-1}^{(5)} + \varepsilon_{i,t},$$

avec

$$y_{i,t-1}^{(5)} = \frac{1}{5} \sum_{k=1}^{5} y_{i,t-k}$$

- Résultat : les **résidus** $\varepsilon_{i,t}$ servent de nouvelles variables pour les GGM et CGGM.

Qu'est-ce qu'un Gaussian Graphical Model (GGM) ?

- Méthode statistique pour analyser des données multivariées continues
- Comprendre comment ces variables interagissent entre elles
- Représente les relations entre variables sous forme de graphe
- Objectif : identifier des **relations directes** entre variables

Les GGM vont au-delà des corrélations classiques.

Pourquoi utiliser les GGM ?

- Lorsqu'on étudie plusieurs variables simultanément, les corrélations ne suffisent pas
- Les corrélations mélangent effets directs et indirects
- Deux variables peuvent être liées uniquement via une troisième
- Les GGM permettent une interprétation plus claire des relations

Particulièrement adaptés aux systèmes économiques complexes où de nombreux indicateurs interagissent entre eux.

Fonctionnement général des GGM (1/2)

- On considère un vecteur aléatoire de variables continues

$$X = (X_1, \ldots, X_p)^\top$$

- On suppose que X suit une loi normale multivariée

$$X \sim \mathcal{N}(\mu, \Sigma)$$

- μ : vecteur des moyennes
- Σ : matrice de covariance

Cette hypothèse est essentielle car, dans le cadre gaussien, les dépendances conditionnelles sont entièrement capturées par la matrice de précision.

Fonctionnement général des GGM (2/2)

- Les relations globales entre variables sont décrites par la matrice de covariance Σ
- Cette matrice mélange relations directes et indirectes
- On introduit la matrice de précision :

$$\Theta = \Sigma^{-1}$$

- Σ : matrice de covariance
- Θ : matrice de précision
- Un coefficient nul dans Θ indique une indépendance conditionnelle directe entre deux variables

Les relations indirectes sont ainsi éliminées.

Construction du graphe

- Les nœuds du graphe représentent les variables $X_1, \ldots, X_p$
- Le graphe est non orienté
- Une arête relie deux variables si leur coefficient dans Θ est non nul
- L'absence d'arête correspond à une indépendance conditionnelle

La structure du graphe est directement déterminée par la matrice de précision.

Lecture d'un Gaussian Graphical Model

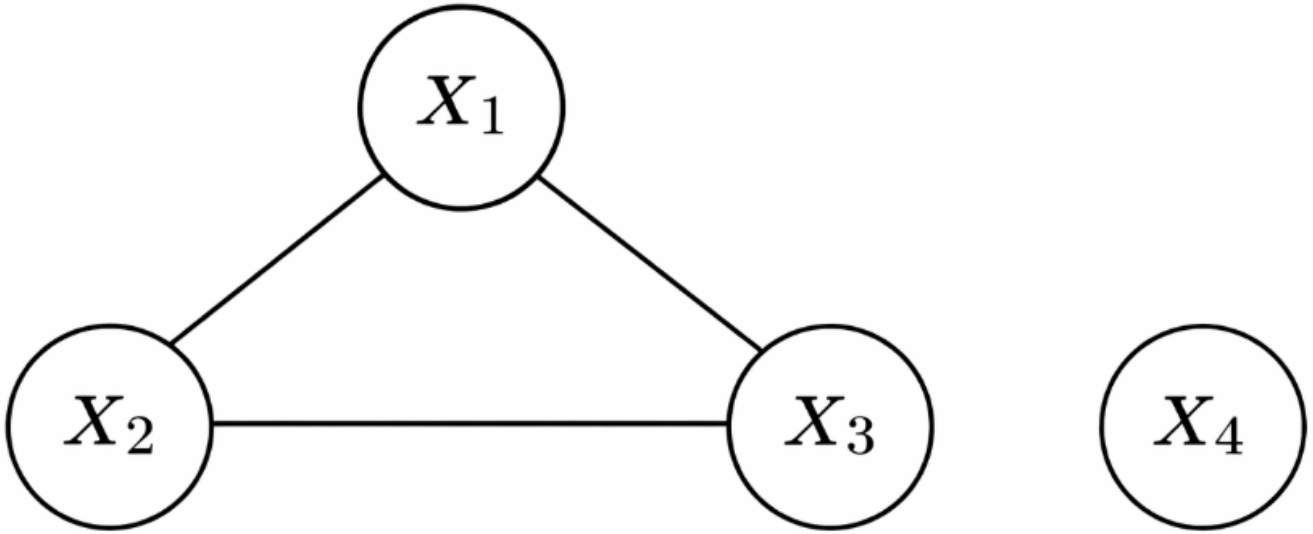

- Les nœuds representent les variables
- X_1, X_2 et X_3 sont directement liés
- X_4 est isolée : indépendante des autres variables

Estimation du GGM

- En réalité, la matrice de précision n'est pas observée et doit être estimée à partir des données
- Sans contrainte, l'estimation conduit généralement à un graphe très dense
- La méthode la plus couramment utilisée est le *graphical lasso*
- Cette méthode pénalise la complexité du modèle
- Ici, cette pénalisation permet de forcer certaines relations faibles à disparaître
- Elle permet d'obtenir des graphes plus simples et plus lisibles

Application des GGM aux données

- Application des Gaussian Graphical Models aux données macroéconomiques
- Données prétraitées afin de tenir compte de leur dynamique temporelle
- Estimation de la matrice de précision par la méthode du graphical lasso
- Objectif : Analyser la structure de dépendances conditionnelles entre les variables macroéconomiques

Lecture du Gaussian Graphical Model

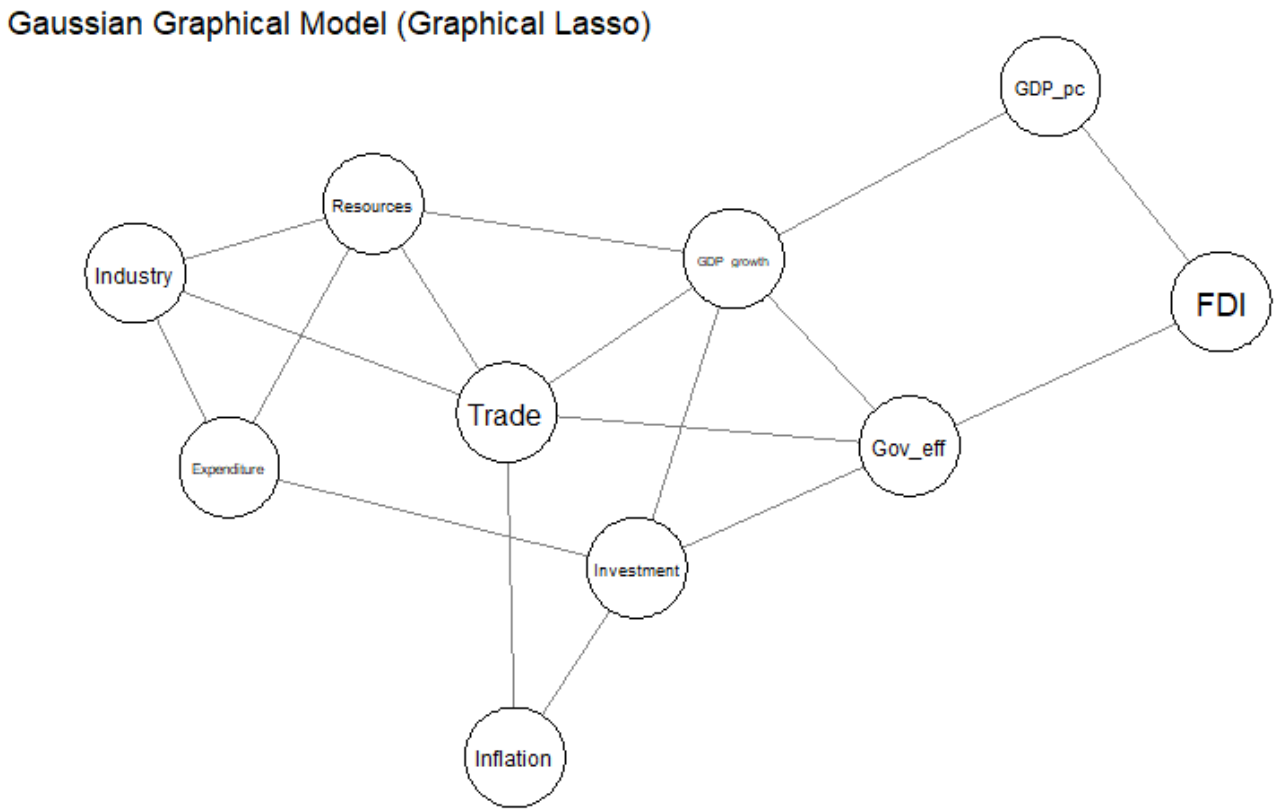

- La croissance du PIB est directement liée au commerce, une fois les autres variables contrôlées.
- Les ressources naturelles et les institutions occupent une position centrale, structurant les relations macroéconomiques

Conclusion et limites des GGM

- Les GGM permettent d'identifier des relations directes entre variables
- Ils améliorent l'interprétation par rapport aux corrélations
- Toutefois, le graphe peut rester dense et difficile à lire globalement
- Cela motive l'introduction du Clusterpath GGM

Principe de la méthode CGGM

- Certaines variables ont des relations et des variances conditionnelles similaires
- CGGM cherche à :
  - regrouper ces variables en clusters
  - estimer un graphe entre clusters plutôt qu'entre variables individuelles
- Cela induit une structure en blocs dans Θ

Qu'est ce qu'une structure en blocs

- Les variables sont partitionnées en K clusters.
- Variables d'un même cluster ont les:
  - mêmes variances conditionnelles
  - mêmes dépendances conditionnelles avec les autres clusters.
- Résultat : réduction de dimensions

Formulation de l'optimisation (1/2)

On redéfinit Θ comme:

$$\Theta = URU^T + A$$

Où:

- $U(p * K)$ est la matrice d'appartenance aux clusters
- $R(K * K)$ est une matrice symétrique
- $A = \mathrm{diag}(a_{11} I_{p_1}, \ldots, a_{KK} I_{p_K})$

Formulation de l'optimisation (2/2)

On estime Θ en résolvant :

$$\underset{\Theta}{argmin} \; -\log|\Theta| + \mathrm{tr}(S\Theta) + P(\Theta) \quad st \quad \Theta = \Theta^T; \Theta > 0$$

- S : covariance empirique,
- $-\log|\Theta| + \mathrm{tr}(S\Theta)$: log-vraisemblance gaussienne,
- $P(\Theta)$: pénalisation

Pénalité CGGM

$$P(\Theta) = \lambda_c \sum_{j<j'} w_{jj'} d_{jj'}(\Theta) \; + \; \lambda_s \sum_{j \neq j'} |\theta_{jj'}|$$

- Deux composantes :
  - agrégation (clustering)
  - λ_c : force du clustering
  - sparsité (suppression d'arêtes)
  - λ_s : force de la sparsité
  - $w_{jj'}$: poids de similarité entre variables
  - $d_{jj'}(\Theta)$ mesure la distance entre les colonnes j et j' de Θ.
  - Si $d_{jj'}(\Theta) = 0$:
    - les variables j et j' ont exactement le même rôle,
    - elles sont fusionnées dans un même cluster.

Application du CGGM (1/2)

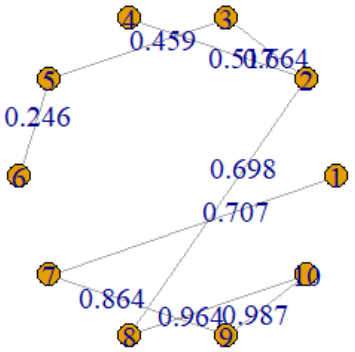

Figure: Matrice de poids pour tout les pays

Application du CGGM (2/2)

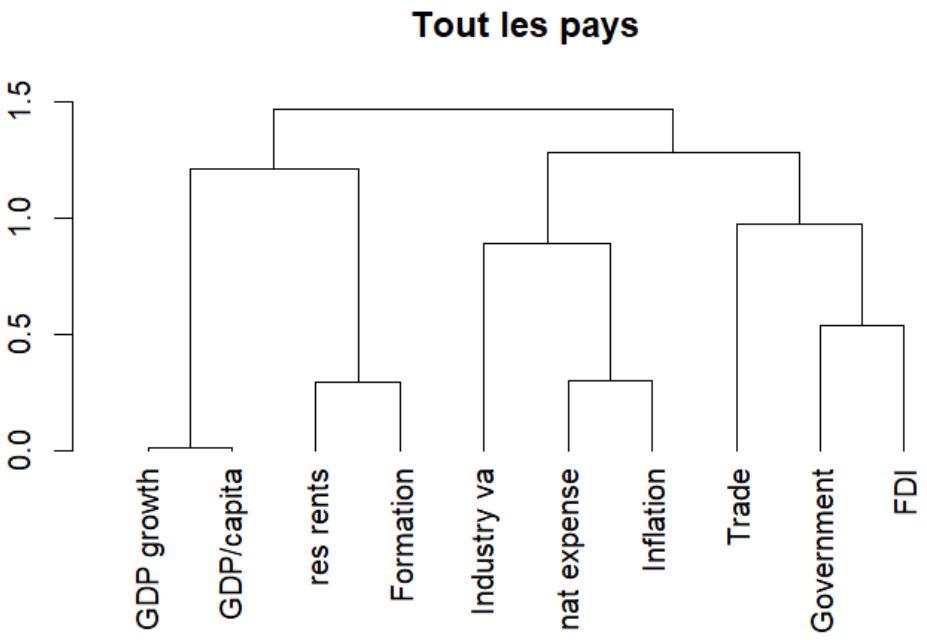

Figure: Dendogramme pour tout les pays

Application des CGGM sur deux groupes de pays

- Objectif : comparer la **structure économique** des pays **industrialises** et des pays **riches en ressources naturelles**.
- Séparation des pays basée sur le **taux de rentes des ressources naturelles (% du PIB, 2021)** :
  - **Pays industrialisés :** $taux < 10\%$ (ex. France, États-Unis, Japon, Allemagne. . .)
  - **Pays riches en ressources :** $taux \geq 10\%$ (ex. Norvège, Russie, Algérie. . .)
- Méthodologie : appliquer la **CGGM** sur chacun des deux groupes afin d'identifier les clusters de variables et comparer la structure économique.
- Les résidus du modèle **HAR** sont utilisés comme données d'entrée, pour neutraliser les dépendances temporelles intra-pays.

Pays industrialisés 1/2

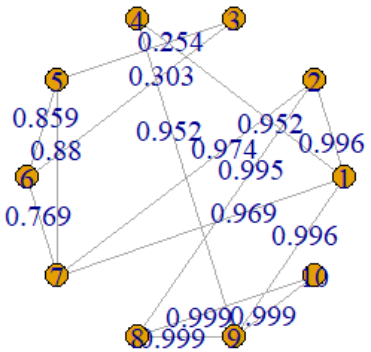

Figure: Matrice de poids pour les pays industrialisés

- Coefficients plus élevés, indiquant une économie similaire entre ces pays.
- La variable **Formation** reste isolée, peu corrélée aux autres indicateurs.

Pays industrialisés 2/2

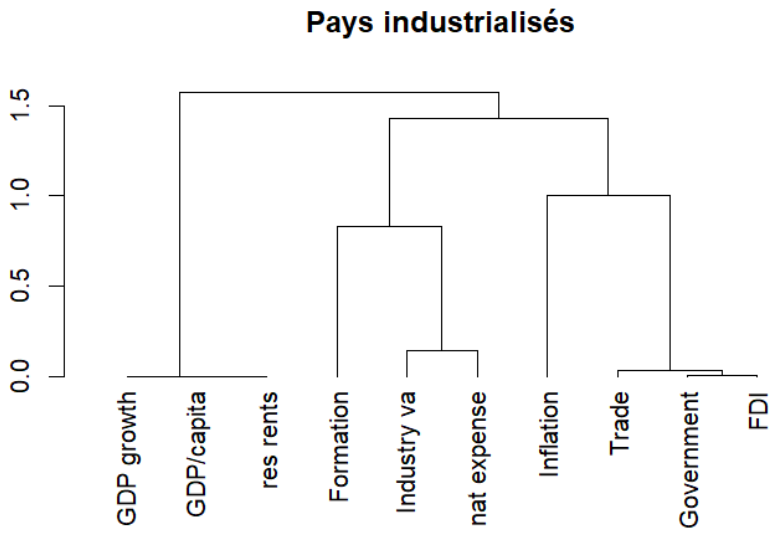

Figure: Dendrogramme pour les pays industrialisés

Deux clusters principaux se distinguent clairement :

- **Cluster 1 :** Croissance du PIB, PIB par habitant, rentes des ressources naturelles
- **Cluster 2 :** Commerce de marchandises (% du PIB), efficacité du gouvernement, investissements étrangers

Pays riches en ressources 1/2

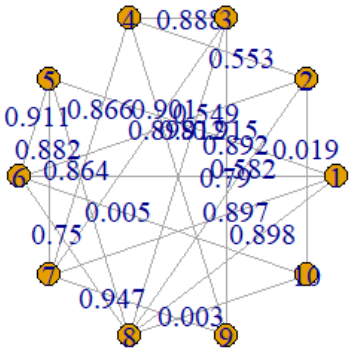

Figure: Matrice de poids pour les pays riches en ressources

- Relations beaucoup plus complexes, interdépendances fortes entre certaines variables et très faibles entre d'autres.
- Structure différente de celle des autres groupes de pays.

Pays riches en ressources 2/2

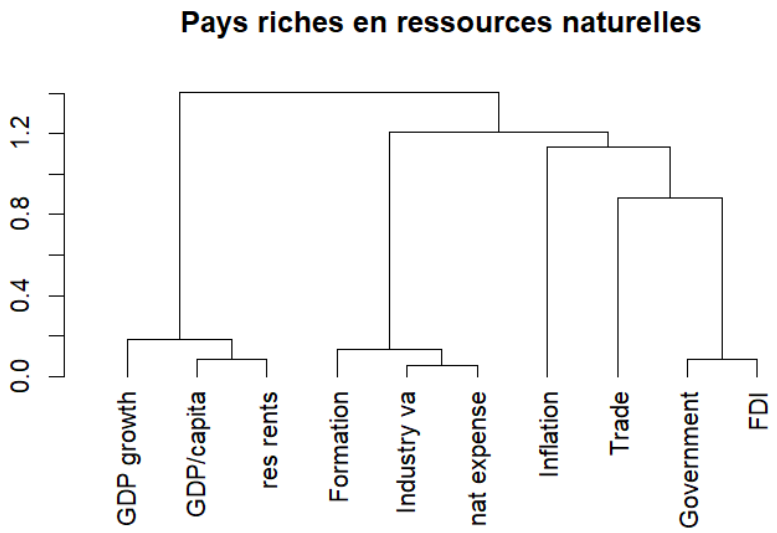

Figure: Dendrogramme pour les pays riches en ressources

Trois clusters principaux se distinguent :

- **Cluster 1 :** Croissance du PIB, PIB/capita, rentes des ressources naturelles (similaire aux pays industrialisés)
- **Cluster 2 :** Formation, valeur ajoutée industrielle, dépenses nationales (différent des pays industrialisés)
- **Cluster 3 :** Efficacité du gouvernement et investissements étrangers

Cas particulier : la Norvège

- La Norvège se situe au seuil du critère utilisé pour distinguer les pays riches en ressources naturelles (**rentes 10% du PIB en 2021**).
- Son positionnement intermédiaire la rend intéressante pour la comparer aux
  - Les structures économiques des pays riches en ressources
  - Les structures des pays industrialisés
- Objectif : observer la structure de dépendances conditionnelles de la Norvège et identifier si elle se rapproche davantage des pays industrialisés ou des pays riches en ressources naturelles.

Comparaison : Norvège vs Pays riches en ressources

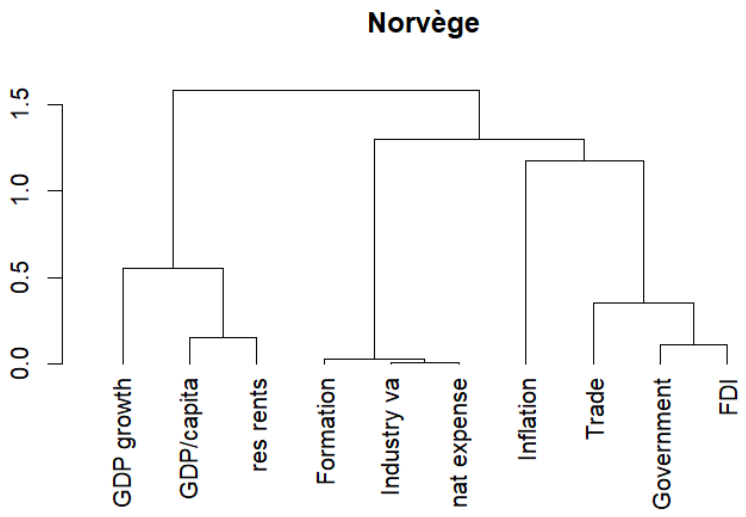

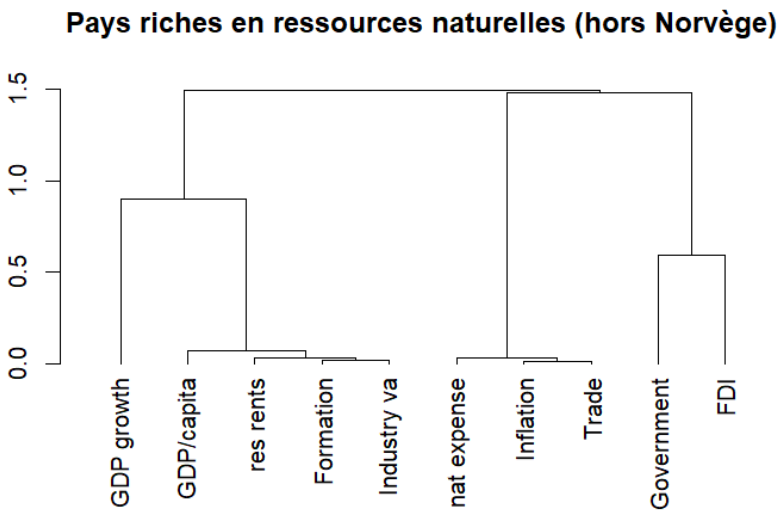

Comparaison : Norvège vs Pays industrialisés

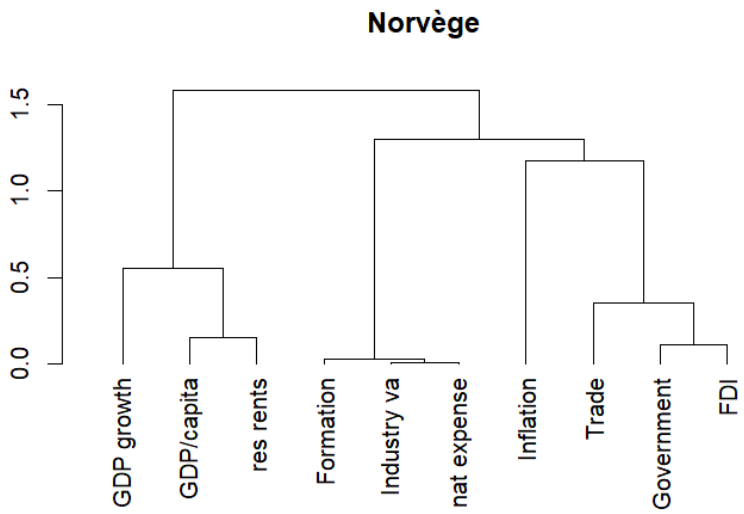

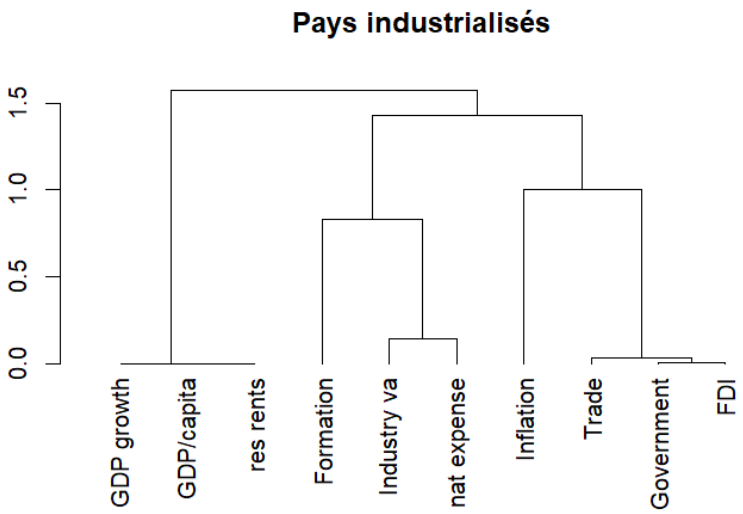

Résultats et analyse : GGM

Résultats

- Identification des relations directes entre variables macroéconomiques
- Graphe dense illustrant les dépendances conditionnelles

Avantages

- Clarifie les relations par rapport aux corrélations classiques
- Méthode statistiquement rigoureuse

Inconvénients

- Graphe parfois dense et difficile à interpréter
- Dépend fortement de l'hypothèse de normalité multivariée

Résultats et analyse : CGGM

Résultats

- Détection de clusters de variables fortement liées
- Simplification et hiérarchisation du graphe pour tous les pays

Avantages

- Graphe plus lisible
- Hiérarchisation des relations sur la structure globale

Inconvénients

- Dépend du choix des paramètres de régularisation