Survey Sampling
IPPS : Inclusion Probability Proportional-to-Size sampling designs

PICART NAJI LAHAY

TSE

27 novembre 2025

Plan

1. Introduction
2. Definition Générale
3. Premier Plan : IPPSWR
4. Deuxième plan : IPPSWOR - Méthode Poisson
5. Deuxième plan : IPPSWOR – Procédure Rao–Sampford
6. Comparaison des 3 méthodes IPPS
7. Conclusion

Motivation

- Le SRS peut être inefficace lorsque la population est **très hétérogène**.
- Certaines unités contribuent énormément au total d'intérêt.
- On dispose d'une **variable de taille** x_i qui reflète l'importance des unités.
- Idée : utiliser x_i pour sur-échantillonner les unités « importantes ».

Définition générale des plans IPPS

- Chaque unité i possède une **variable de taille** $x_i > 0$ connue avant le tirage.
- Le principe d'un plan IPPS est d'attribuer des probabilités d'inclusion plus élevées aux unités ayant un x_i important.
- Cela est particulièrement efficace lorsque x et la variable d'intérêt y sont **positivement corrélées**.
- Il existe différents mécanismes pour réaliser un plan IPPS : **avec remise** et **sans remise**.

Premier plan : IPPSWR

- À chaque tirage, sélection d'une unité i avec probabilité :

$$p_i = \frac{x_i}{X}, \qquad X = \sum_{k=1}^{N} x_k.$$

- Tirages **avec remise** : indépendants, unités pouvant être tirées plusieurs fois.
- Simple à implémenter et compatible avec l'estimateur de Hansen–Hurwitz.

Méthode de sélection IPPSWR : procédure des sommes cumulées

1. Calcul des probabilités cumulées :

$$p_1,\ p_1 + p_2,\ \ldots,\ p_1 + \cdots + p_N.$$

2. Tirage d'un nombre $r \sim \mathcal{U}(0,1)$.
3. Sélection de l'unité i telle que :

$$p_1 + \cdots + p_{i-1} < r \leq p_1 + \cdots + p_i.$$

Répéter n fois pour obtenir l'échantillon IPPSWR.

Estimateur de Hansen–Hurwitz (1/2)

- Total de la population :

$$Y = \sum_{i=1}^{N} y_i.$$

- On observe un échantillon s obtenu par IPPSWR, avec multiplicité possible.
- L'estimateur Hansen–Hurwitz du total est :

$$\widehat{Y}_{HH} = \frac{1}{n} \sum_{i \in s} \frac{y_i}{p_i}.$$

Estimateur de Hansen–Hurwitz (2/2)

- Non biaisé :

$$\mathbb{E}\left[\widehat{Y}_{HH}\right] = Y.$$

- Variance théorique :

$$\mathrm{Var}(\widehat{Y}_{HH}) = \frac{1}{n}\sum_{i\in U} p_i \left(\frac{y_i}{p_i} - Y\right)^2.$$

- Variance estimée :

$$\widehat{\mathrm{Var}}(\widehat{Y}_{HH}) = \frac{1}{n(n-1)}\sum_{i\in s} \left(\frac{y_i}{p_i} - \widehat{Y}_{HH}\right)^2.$$

Données : `belgianmunicipalities`

- Population : 589 communes belges.
- Variable de taille : **Tot04** (population 2004).
- Variable d'intérêt : **TaxableIncome**.
- Total réel :

$$Y = 1.2113 \times 10^{11}.$$

Statistiques descriptives

Tot04	
Total	10 417 122
Moyenne	17 686
Médiane	11 432
Écart-type	27 932
Min	86
Max	457 319

TaxableIncome	
Total	1.21×10^{11}
Moyenne	2.06×10^{8}
Médiane	1.34×10^{8}
Écart-type	3.21×10^{8}
Min	1.10×10^{6}
Max	5.42×10^{9}

Population très hétérogène $\Rightarrow$ contexte idéal pour IPPS.

Simulations Monte-Carlo (1/2)

- Nous réalisons **1000 réplications indépendantes**.
- À chaque réplication :
  - échantillon IPPSWR de **taille 100**,
  - calcul de l'estimateur Hansen–Hurwitz :

$$\widehat{Y}_{HH}^{(i)}.$$

- On obtient donc **1000 estimateurs Hansen–Hurwitz**.
- La moyenne Monte-Carlo s'écrit :

$$\widehat{Y}_{HH,MC} = \frac{1}{1000} \sum_{i=1}^{1000} \widehat{Y}_{HH}^{(i)}.$$

Résultats

$$Y = 1.2113 \times 10^{11}, \qquad \widehat{Y}_{HH,MC} = 1.2114 \times 10^{11}.$$

L'estimateur est pratiquement exact $\Rightarrow$ **non biaisé**.

Simulations Monte-Carlo (2/2)

Erreurs

$$\left|\widehat{Y}_{HH,MC} - Y\right| = 1.26 \times 10^7,$$

$$\text{Erreur relative} = 0.01\%.$$

Variances

$$\mathrm{Var} = 3.32 \times 10^{18}, \qquad \widehat{\mathrm{Var}}_{MC} = 3.50 \times 10^{18}.$$

Les variances sont très proches : la simulation est cohérente.

Comparaison avec SRSWOR

- Estimation sous SRSWOR :

$$\widehat{Y}_{SRSWOR} = 1.1812 \times 10^{11}.$$

- Erreur absolue sous SRSWOR :

$$|\widehat{Y}_{SRSWOR} - Y| = 3.01 \times 10^{9}.$$

- Sous IPPSWR :

$$|\widehat{Y}_{HH,MC} - Y| = 1.26 \times 10^{7}.$$

IPPSWR est 200 fois plus précis que SRSWOR.

Conclusion IPPSWR

- L'estimateur Hansen–Hurwitz est **non biaisé**.
- Les variances théorique et empirique sont très proches.
- Très bonne précision lorsque x et y sont corrélées.
- Performances très supérieures au SRSWOR.

Deuxième plan : IPPSWOR

- À chaque tirage, sélection d'une unité i avec probabilité :

$$\pi_i = n\,\frac{x_i}{X}, \qquad i \in U,$$

- Tirages **sans remise** : Les unités sélectionnées ne sont pas remises dans la population
- Nécéssite un algorithme d'échantillonnage comme :
  - Méthode Poisson (n aléatoire),
  - Méthode Rao-Sampford (n fixé)

Procédure de sélection : méthode de Poisson

La méthode de Poisson fixe des probabilités d'inclusion :

$$\pi_i = n\frac{x_i}{\sum_{j=1}^{N} x_j}, \qquad \sum_{i=1}^{N} \pi_i = n.$$

Séléction indépendante :

$$S_i \sim \mathcal{B}(\pi_i).$$

La taille de l'échantillon est aléatoire :

$$n_{\text{réel}} = \sum_{i=1}^{N} S_i, \qquad \mathbb{E}[n_{\text{réel}}] = n.$$

Méthode simple mais en général non optimale en variance.

Estimateur du total d'Horvitz–Thompson

Pour un plan IPPS sans remise, on utilise l'estimateur HT :

$$\hat{Y}_{HT} = \sum_{i \in s} \frac{y_i}{\pi_i}.$$

- s : échantillon sélectionné,
- y_i : valeur observée,
- π_i : probabilité d'inclusion.

Variances :

$$Var(\hat{Y}_{HT}) = \sum_{i \in U} \sum_{j \in U} \Delta_{ij} \frac{y_i}{\pi_i} \frac{y_j}{\pi_j},$$

$$\hat{Var}(\hat{Y}_{HT}) = \sum_{i \in s} \sum_{j \in s} \frac{\Delta_{ij}}{\pi_{ij}} \frac{y_i}{\pi_i} \frac{y_j}{\pi_j}.$$

Application d'un plan IPPS Poisson

Application d'un plan IPPS sans remise basé sur `Tot04` pour estimer le total de `TaxableIncome`.

Monte-Carlo avec 1000 réplications : estimation HT à chaque tirage (taille aléatoire, $\mathbb{E}[n] = 100$).

$$\hat{Y}_{HT,\mathrm{MC}} = \frac{1}{1000} \sum_{i=1}^{1000} \hat{Y}_{HT}^{(i)},$$

$$\widehat{Var}(\hat{Y}_{HT}) = \frac{1}{999} \sum_{i=1}^{1000} (\hat{Y}_{HT}^{(i)} - \hat{Y}_{HT,\mathrm{MC}})^2.$$

Résultats Monte-Carlo

- Total réel :

$$Y = 1.2113 \times 10^{11}.$$

- Estimateur du total :

$$\hat{Y}_{HT,\mathrm{MC}} = 1.2115 \times 10^{11}.$$

- Variance MC :

$$8.21 \times 10^{19}.$$

- Écart-type :

$$9.06 \times 10^{9}.$$

- Coefficient de variation :

$$\mathrm{CV} = 0.0748.$$

L'estimation est très proche du total réel : Erreur relative = 0.02%.

Comparaison avec Bernoulli

Plan Bernoulli (même espérance d'échantillon) :

$$\hat{Y}_{\text{Bernoulli, MC}} = 1.19 \times 10^{11}, \qquad \widehat{Var} = 3.95 \times 10^{20}.$$

Erreur relative : 1.55%.

Conclusion : Le plan IPPSWOR avec méthode de poisson montre :

- une quasi absence de biais
- une très bonne précision
- une variance nettement plus faible que Bernoulli

Deuxième plan : IPPSWOR – Méthode Rao–Sampford

- Plan IPPS avec une taille d'échantillon n fixe.
- Sélection en deux étapes :
  - choix d'une première observation selon une probabilité liée à la variable auxiliaire
  - sélection séquentielle des obsevations restantes avec une probabilité différente

Procédure de sélection : méthode de Rao–Sampford

Première étape : choix d'une première observation i avec :

$$p_i = \frac{x_i}{\sum_{k \in U} x_k}.$$

Deuxième étape : sélection d'une nouvelle observation j selon :

$$\lambda_i = \frac{p_i}{1 - np_i}.$$

Si $i = j$, on recommence la procédure. Sinon, on poursuit jusqu'à obtenir n unités distinctes.

Application d'un plan Rao–Sampford

Monte-Carlo avec 1000 répétitions : estimation HT à chaque tirage (taille fixée $n = 100$).

$$\hat{Y}_{HT,\mathrm{MC}} = \frac{1}{1000} \sum_{i=1}^{1000} \hat{Y}_{HT}^{(i)},$$

$$\widehat{Var}(\hat{Y}_{HT}) = \frac{1}{999} \sum_{i=1}^{1000} (\hat{Y}_{HT}^{(i)} - \hat{Y}_{HT,\mathrm{MC}})^2.$$

Résultats Monte-Carlo

- Moyenne MC : $\hat{Y}_{HT,\text{MC}} = 1.21332 \times 10^{11}$
- Variance MC : $\hat{Var}(\hat{Y}_{HT}) \approx 1.64405 \times 10^{19}$
- Coefficient de variation : $\text{CV} = 0.03$

Comparaison avec SRSWOR (1/2)

Design	**Biais**	$\widehat{\textbf{Var}}$	CV	Erreur relative
SRSWOR	$2,94445 \times 10^9$	2.18112×10^{21}	0.38	2.43%
Rao-Sampford	$8,24428 \times 10^7$	1.64405×10^{19}	0.03	0.16%

Comparaison avec SRSWOR (2/2)

Comparaison SRSWOR vs Rao-Sampford :

- **Biais :** Rao-Sampford présente un biais très faible comparé à SRSWOR.
- **Variance :** Rao-Sampford a une variance beaucoup plus faible.
- **Précision :** Rao-Sampford est beaucoup plus précis (CV et erreur relative beaucoup plus faibles).

Comparaison des 3 méthodes IPPS

Design	**Biais**	$\widehat{\text{Var}}$	**CV**	**Erreur relative**
Somme cumulées	1.2605×10^7	3.48029×10^{18}	1.6	0.01%
Poisson	2.67×10^7	8.21×10^{19}	0.075	0.02%
Rao-Sampford	8.24428×10^7	1.64405×10^{19}	0.03	0.16%

Conclusion

- Un plan de sondage **IPPS** attribue à chaque unité une probabilité d'inclusion proportionnelle à une variable auxiliaire.
- Plusieurs méthodes existent pour construire ces plans :
  - Avec remise : sommes cumulées, méthode de Lahiri (1951)
  - Sans remise : Poisson (taille aléatoire), Rao-Sampford, Brewer (taille fixe)
- Les plans IPPS sont généralement plus efficaces que SRSWOR ou le plan de Bernoulli, mais l'efficacité dépend du contexte.
- Conditions favorables à l'efficacité :
  - Probabilités d'inclusion équiprobables
  - Variable d'intérêt Y fortement corrélée à la variable auxiliaire X, avec une relation passant par l'origine
- Les plans IPPS ne sont pas systématiquement supérieurs, mais restent adaptés aux situations où ces conditions sont vérifiées et constituent des alternatives intéressantes ailleurs.