Méthodes de validation et estimation

Modèles de survie paramétriques

Introduction

- Dans le cours, nous avons étudié des méthodes de survie **non paramétriques** (Kaplan–Meier) et **semi-paramétriques** (modèle de Cox).
- Ces approches permettent de décrire les durées observées et d'analyser l'effet des covariables, avec peu d'hypothèses sur la distribution.
- Cependant, dans des domaines comme l'assurance, on souhaite aussi modéliser explicitement la distribution du temps et effectuer des projections à long terme.
- Cela motive l'utilisation des **modèles de survie paramétriques**.

Avantages des modèles de survie paramétriques

- Description complète de la distribution du temps jusqu'à l'événement
- Forme du risque explicitement modélisée
  - risque constant, croissant, décroissant ou non monotone
- Possibilité d'extrapolation à long terme
- Calcul direct de quantités actuarielles
  - probabilités à horizon, durées moyennes, **prévisions**

Définition : modèle de survie paramétrique

Définition

Le temps jusqu'à l'événement T est supposé suivre une loi paramétrique sur $\mathbb{R}_+$, définie par un nombre fini de paramètres.

- Une loi paramétrique définit complètement :
  - la fonction de survie $S(t)$,
  - le risque instantané $h(t)$,
  - la densité $f(t)$.
- La spécification paramétrique permet des calculs complets sur la distribution du temps jusqu'à l'événement T, notamment l'espérance et des prévisions à long terme.

Distributions paramétriques : Exponentielle et Weibull

Loi exponentielle

$$T \sim \mathrm{Exp}(\lambda)$$

$$h(t) = \lambda, \qquad S(t) = \exp(-\lambda t)$$

- Modèle de référence
- λ : intensité du risque
- Pas de dépendance au temps

Loi de Weibull

$$T \sim \mathrm{Weibull}(\alpha, \lambda)$$

$$h(t) = \lambda \alpha t^{\alpha-1}, \qquad S(t) = \exp(-\lambda t^{\alpha})$$

- α : paramètre de forme
- Risque croissant si $\alpha > 1$, décroissant si $\alpha < 1$
- Cas $\alpha = 1$: exponentielle

Distributions paramétriques : Log-normale et Log-logistique

Loi log-normale

$$\log(T) \sim \mathcal{N}(\mu, \sigma^2)$$

$$S(t) = 1 - \Phi\left(\frac{\log t - \mu}{\sigma}\right)$$

- μ, σ : position et dispersion
- Risque non monotone (en cloche)
- Durées asymétriques

Loi log-logistique

$$T \sim \mathrm{LogLogistic}(\alpha, \lambda)$$

$$h(t) = \frac{\alpha\lambda t^{\alpha-1}}{1 + \lambda t^{\alpha}}, \qquad S(t) = \frac{1}{1 + \lambda t^{\alpha}}$$

- Risque en cloche (montée puis baisse)
- Sélection des survivants
- Alternative à la log-normale

Distributions paramétriques : Gompertz et Gamma généralisée

Loi de Gompertz

$$T \sim \mathrm{Gompertz}(\lambda, \gamma)$$

$$h(t) = \lambda e^{\gamma t}, \qquad S(t) = \exp\left(-\frac{\lambda}{\gamma}\left(e^{\gamma t} - 1\right)\right)$$

- γ : vitesse d'augmentation du risque
- Modélisation de la mortalité
- Assurance-vie / démographie

Gamma généralisée

$$T = e^{\alpha + \sigma W}$$

- Loi très flexible pour les durées
- α, σ contrôlent l'échelle et la forme
- Exemple :
  - pour certains paramètres $\Rightarrow$ loi de Weibull
- Utile lorsque la forme du risque est a priori inconnue

Introduire des covariables : PH et AFT

- Il existe deux grandes manières d'introduire des covariables dans un modèle de survie.

Modèles à risques proportionnels (PH)

- Effet des covariables sur le **risque**
- Modèle de Cox, **déjà étudié en cours**

Modèles à durées de vie accélérées (AFT)

- Effet des covariables sur le **temps jusqu'à l'événement**
- Approche **paramétrique** que l'on va détailler

Pourquoi s'intéresser aux modèles AFT ?

- Les modèles PH décrivent l'effet des covariables en termes de **risque relatif**.
- Les modèles AFT proposent une interprétation **directement en termes de durées**.
- Ils s'intègrent naturellement dans un cadre **paramétrique**.

Dans la suite, on se concentre sur les **modèles AFT**.

Modèle à durées de vie accélérées (AFT)

Définition

Le modèle AFT suppose une relation linéaire entre le logarithme du temps jusqu'à l'événement et les covariables :

$$\log(T) = X^\top \beta + \varepsilon,$$

où ε suit une loi paramétrique.

- Les covariables ont un **effet multiplicatif sur le temps** T
- Le facteur $\exp(\beta_j)$ mesure un **ratio de durées**

Exemple :
Si $\exp(\beta_j) = 1.3$ pour une covariable donnée, alors la **durée moyenne avant rachat d'un contrat** est environ **30% plus longue**, toutes choses égales par ailleurs.

Illustration R : données `uslapseagent`

Contexte

- Portefeuille de contrats d'**assurance vie entière** (Whole Life)
- Commercialisés via des **agents exclusifs** aux États-Unis
- Période d'observation : **1995–2008**

Structure des données

- 29 317 contrats observés
- Variable de durée : `duration` (ancienneté en trimestres)
- Censure à droite pour les contrats encore en vigueur

Événement étudié

- Sortie du contrat **toutes causes confondues**
- Variable indicatrice : `allcause`

Illustration R : modèle AFT exponentiel

Modèle estimé

$$\log(T) = X^\top \beta + \varepsilon \qquad \text{(AFT exponentiel, estimation via } \texttt{survreg}\text{)}$$

Covariables incluses

- sexe (`gender`)
- statut tabagique (`risk.state`)
- fractionnement des primes (`premium.frequency`)
- prime annuelle (`annual.premium`)
- âge à la souscription (`underwriting.age`)

Modèle AFT exponentiel : résultats

Covariable	**Coef.**	**Time ratio** $\exp(\beta)$
gender = Male	-0.076	0.93
risk.state = Smoker	0.094	1.10
premium.freq = InfraAnnual	-0.232	0.79
premium.freq = Other	0.112	1.12
annual.premium (std.)	-0.118	0.89
underwriting.age = Old	0.248	1.28
underwriting.age = Young	0.071	1.07

Interprétation

- **Paiement fractionné de la prime** : les assurés ont tendance à **résilier leur contrat plus rapidement**
- **Prime annuelle élevée** : la sortie du contrat intervient **plus tôt**
- **Âge élevé à la souscription** : les assurés **conservent leur contrat plus longtemps**

Pourquoi valider une distribution ?

- Les modèles paramétriques reposent sur une hypothèse forte sur la loi des durées
- Différence fondamentale :
  - Kaplan–Meier : approche empirique (descriptive)
  - Modèles paramétriques : approche prédictive et interprétable
- Une mauvaise spécification $\Rightarrow$ biais sur les paramètres et les prédictions

Le choix de la distribution est une étape clé.

Démarche méthodologique

1. **Approche graphique** : identification de la forme du risque
2. **Approche par ajustement** : sélection (AIC / BIC)
3. **Diagnostics de validation** : résidus et QQ-plots

Méthodes complémentaires, jamais utilisées isolément.

Graphiques de probabilité

Principe

- Transformation de $\hat{S}(t)$ et de l'axe des temps

Graphiques de probabilité

Principe

- Transformation de $\hat{S}(t)$ et de l'axe des temps
- Si la loi supposée est correcte $\Rightarrow$ alignement sur une droite

Interprétation

- Linéarité : distribution plausible
- Courbure ou rupture : loi inadaptée

Transformations graphiques par loi

Distribution	Transformation	Axe des temps
Exponentielle	$-\ln S(t)$	t
Weibull	$\ln[-\ln S(t)]$	$\ln t$
Log-logistique	$\ln(1/S(t)-1)$	$\ln t$
Log-normale	$\Phi^{-1}(1-S(t))$	$\ln t$
Gompertz	$\ln h(t)$	t

Alignement linéaire $\Rightarrow$ loi candidate.

Survie ajustée vs Kaplan–Meier

- Comparaison entre :
  - $\hat{S}(t)$ Kaplan–Meier
  - $S(t)$ issu du modèle paramétrique

Survie ajustée vs Kaplan–Meier

- Comparaison entre :
  - $\hat{S}(t)$ Kaplan–Meier
  - $S(t)$ issu du modèle paramétrique
- Superposition étroite $\Rightarrow$ bon ajustement global

Survie ajustée vs Kaplan–Meier

- Comparaison entre :
  - $\hat{S}(t)$ Kaplan–Meier
  - $S(t)$ issu du modèle paramétrique
- Superposition étroite $\Rightarrow$ bon ajustement global
- Écarts systématiques (début/fin) $\Rightarrow$ mauvaise spécification

Critères d'information

Définitions

$$AIC = -2 \ln L + 2p$$

$$BIC = -2 \ln L + p \ln n$$

Critères d'information

Définitions

$$AIC = -2 \ln L + 2p$$

$$BIC = -2 \ln L + p \ln n$$

- Comparaison de modèles non-emboîtés
- Plus petite valeur $\Rightarrow$ meilleur compromis ajustement/parcimonie
- BIC pénalise plus fortement la complexité

Résidus de Cox–Snell

$$r_i = \hat{H}(T_i \mid X_i) = -\ln \hat{S}(T_i \mid X_i)$$

Résidus de Cox–Snell

$$r_i = \hat{H}(T_i \mid X_i) = -\ln \hat{S}(T_i \mid X_i)$$

- Si le modèle est correct :
- $r_i \sim$ Exponentielle(1)

Résidus de Cox–Snell

$$r_i = \hat{H}(T_i \mid X_i) = -\ln \hat{S}(T_i \mid X_i)$$

- Si le modèle est correct :
- $r_i \sim$ Exponentielle(1)

Validation graphique

Hasard cumulé des résidus vs r_i
Alignement sur $y = x$

Estimation par Maximum de Vraisemblance

- Méthode standard pour les modèles paramétriques

Estimation par Maximum de Vraisemblance

- Méthode standard pour les modèles paramétriques
- Intègre naturellement la censure

$$L(\theta) = \prod_{i=1}^{n} f(t_i|x_i)^{\delta_i} S(t_i|x_i)^{1-\delta_i}$$

Estimation par Maximum de Vraisemblance

- Méthode standard pour les modèles paramétriques
- Intègre naturellement la censure

$$L(\theta) = \prod_{i=1}^{n} f(t_i|x_i)^{\delta_i} S(t_i|x_i)^{1-\delta_i}$$

Optimisation numérique (Newton–Raphson).

Conclusion et recommandations

1. Toujours commencer par une analyse graphique

Conclusion et recommandations

1. Toujours commencer par une analyse graphique
2. Tester plusieurs distributions et comparer via AIC/BIC

Conclusion et recommandations

1. Toujours commencer par une analyse graphique
2. Tester plusieurs distributions et comparer via AIC/BIC
3. Valider avec les résidus de Cox–Snell

Conclusion et recommandations

1. Toujours commencer par une analyse graphique
2. Tester plusieurs distributions et comparer via AIC/BIC
3. Valider avec les résidus de Cox–Snell
4. En cas de doute : modèle de Cox

Les graphiques restent indispensables.